

TD Assemblage 1 - L3 Gr.C

Josua Philippot

3 avril 2020

Exercice 1

Soit les familles suivantes :

F1 = ACCTGAG
F2 = TGCATTGC
F3 = GCAGACC
F4 = AGCAAT
F5 = CAATG

Exécutons l'algorithme glouton vu en cours sur ces familles :

Etape 1 :

	F1	F2	F3	F4	F5
F1		0	1	2	0
F2	0		2	0	1
F3	3	0		0	1
F4	0	0	0		4
F5	0	2	1	0	

On remarque que le plus gros chevauchement est entre F4 et F5 en effet $\text{overlap}(F4, F5) = 3$, celui-ci fait référence à la séquence 'CAAT' qui apparaît en fin de la chaîne F4 et au début de F5.

On obtient donc la concaténation $F_{4,5}$: AGCAATG

Etape 2 :

	F1	F2	F3	$F_{4,5}$
F1		0	1	2
F2	0		2	0
F3	3	0		0
$F_{4,5}$	0	2	1	

On remarque que le plus gros chevauchement est entre F3 et F1, en effet $\text{overlap}(F3, F1) = 3$, avec la séquence 'ACC' qui apparaît en fin de la chaîne F3 et au début de F1.

On obtient donc par concaténation $F_{3,1}$: GCAGACCTGAG

Etape 3 :

	$F_{3,1}$	F2	$F_{4,5}$
$F_{3,1}$		0	2
F2	2		0
$F_{4,5}$	1	2	

Ici on a deux chevauchement qui nous intéressent car ils ont tout deux une valeur maximale. Comme il faut en choisir qu'un, on va prendre le premier que l'on rencontre en parcourant le tableau, soit $\text{overlap}(F_{3,1}, F_{4,5}) = 2$. Celui-ci concerne la séquence 'AG' qui est présente à la fin de la chaîne $F_{3,1}$ et au début de $F_{4,5}$

On obtient donc par concaténation $F_{3,1,4,5}$: CAATGCATTGCAGACCTGAG

Etape 4 :

	$F_{3,1,4,5}$	F2
$F_{3,1,4,5}$		2
F2	2	

Enfin pour le dernier chevauchement on procède comme précédemment et on trouve $\text{overlap}(F_{3,1,4,5}, F_2) = 2$, celui-ci correspond à la séquence 'TG' que l'on retrouve en fin de $F_{3,1,4,5}$ et au début de F2.

On peut donc effectuer la dernière concaténation qui nous donne $F_{3,1,4,5,2}$: GCAGACCTGAGCAATGCATTGC la chaîne finale, de longueur 22.

Exercice 2

Algorithme 1 : superChaineGlouton

Entrées : $\mathbf{F} = \{F_1, F_2, \dots, F_n\}$ un ensemble de chaînes.

Sorties : **Sup** une chaîne de caractère contenant la superchaîne extraite de \mathbf{F} .

Données : **Sup** un ensemble de chaînes, **nbCommun** un entier, **X** et **Y** des chaînes de caractères.

```
1 début
2   Sup  $\leftarrow \mathbf{F}$ ;
3   nbCommun  $\leftarrow 0$ ;
4   X, Y  $\leftarrow \emptyset$ ;
5   tant que Sup contient plus d'une chaîne de caractère faire
6       pour tout les mots  $m_1$  de Sup faire faire
7           pour tout les mots  $m_2$  de Sup tel que  $m_2 \neq m_1$  faire
8               si nbCommun == 0 alors
9                   X  $\leftarrow m_1$ ;
10                  Y  $\leftarrow m_2$ ;
11              finSi
12              temp  $\leftarrow \text{overlap}(m_1, m_2)$ ;
13              si nbCommun < temp alors
14                  nbCommun  $\leftarrow$  temp
15                  X  $\leftarrow m_1$ ;
16                  Y  $\leftarrow m_2$ ;
17              finSi
18              On supprime  $m_1$  et  $m_2$  de Sup;
19              On ajoute à Sup la concaténation des chaînes ( $m_1$  - les nbCommun
20                  derniers caractères ) et  $m_2$ ;
21          finPour
22      finPour
23 fin
```

Cet algorithme à une complexité d'environ $\mathcal{O}(n^3 * x)$ ou n est la taille de l'ensemble \mathbf{F} et x la complexité de l'algorithme *overlap()*.




FIGURE 1 – Graphe des chevauchements

Exercice 3

Le graphe de la figure 1 ci-dessus peut être réaliser à partir de l'algorithme suivant :

Algorithme 2 : constructGraphOverlap

Entrées : $F = \{F_1, F_2, \dots, F_n\}$ un ensemble de chaînes.

Sorties : $G(V, E)$ Le graphe des chevauchement.

Données : $G(V, E)$ Le graphe des chevauchement.

```

1 début
2   Soit  $G(V, E)$  un graphe avec  $V$  les sommets et  $E$  les arêtes.
3    $V \leftarrow F$ ;
4    $A \leftarrow \emptyset$ ;
5   pour tout les mots  $m_1$  de  $V$  faire faire
6     pour tout les mots  $m_2$  de  $V$  tel que  $m_2 \neq m_1$  faire
7        $temp \leftarrow overlap(m_1, m_2)$ ;
8       si  $temp > 0$  alors
9          $A \leftarrow A \cup$  L'arête qui part de  $m_1$  vers  $m_2$  avec un poid de  $temp$ ;
10      finSi
11    finPour
12  finPour
13 fin

```

Cet algo possède une complexité d'environ $\mathcal{O}(n^2 * x)$ avec n le nombre de chaîne de F et x la complexité de l'algorithme *overlap()*.

Exercice 4

Algorithme 3 : cycleHamiltonienGlouton

Entrées : $G(V, E)$ un graphe de chevauchement.
Sorties : H un chemin hamiltonien (Un ensemble d'arêtes).
Données : H un ensemble d'arête. O un sommet.

```

1 début
2    $H \leftarrow \emptyset$ 
3   tant que  $E \neq \emptyset$  faire
4      $temp \leftarrow$  L'arête de  $E$  de poid maximal ;
      /*Si on a plusieurs arêtes de poid maximal on prend la première qui arrive*/
       $O \leftarrow$  Le sommet à l'origine de l'arête stockée en  $temp$  ;
       $H \leftarrow H \cup temp$  ;
       $E \leftarrow E$  privé des arêtes qui ont pour origine  $O$  ;
5   finTq
6   retourner  $H$ 
7 fin
  
```

Cet algorithme a une complexité d'environ $\mathcal{O}(n * x)$ avec x la complexité de pour l'action qui permet de prendre "L'arête de E de poid maximal"

On remarque sur la figure 2 ci-dessous, que l'on retrouve la superchaîne de l'exercice 1 si on suit le cycle hamiltonien.




FIGURE 2 – H le chemin hamiltonien